

일반국민/대학(원)생 부문

제6회 K-인공지능 제조데이터

분석 경진대회 보고서

항목	내용
프로젝트명	X-ray 이물 탐지와 조건별 오류 분석 기반 재검사 설계
팀명	
내용 요약	X-ray 사진에서 이물 위치를 찾는 모델을 개발한다. 색 네모를 제거하고 촬영 묶음에 따라 데이터를 나눈다. 같은 학습 자료로 서로 다른 탐지 구조를 비교한다. 전체 성능과 조건별 오류를 함께 분석하여 재검사 기준을 제안한다. 이 검토본은 EDA, 전처리, 네 모델의 공통 20epoch 학습과 선택 저장본의 테스트 결과를 포함한다. 최종 모델과 현장 운영 임계값은 미확정이다.

상기 본인(팀)은 위의 내용과 같이 제6회 K-인공지능 제조데이터 분석 경진대회 결과 보고서를 제출합니다.

2026년 월 일

팀장 : (서명)

팀원 : (서명)

팀원 : (서명)

(사)중소기업기술혁신협회 귀중

제1장 데이터 이해 및 진단

원본 사진과 라벨 제공 데이터셋

분석 대상은 X-ray 검사장비의 이물 탐지 영상이다. 사진 속 작은 검은 점은 주로 시험용 금속구이고, 길쭉한 회색 물체는 검사 감도를 확인하는 시험편 막대다. 실제 생산 중 발생하는 다양한 이물과 정상 제품을 대표한다고 가정하지 않는다.

자료	사진 수	학습과 평가에서의 역할
원본 데이터셋	2,532	중복을 제외한 고유 원본
라벨 제공 데이터셋	500	공식 TXT 라벨이 있는 사진
미라벨 데이터셋	2,032	TXT 없음. 정상이라는 뜻은 아님

원본 BMP 파일은 2,809개다. 고유 사진 2,532장 중 색 네모가 있는 사진은 2,427장이다. 나머지 105장은 노란 위치 안내선만 있는 사진이다. 위치 이상 사진은 대표 정상 제품으로 간주하지 않고 학습에서 제외했다.

공식 TXT에는 이물 1,147개의 종류와 박스 좌표가 있다. 공식 정답 라벨을 학습과 채점의 기준으로 사용한다. 장비가 사진에 그린 색 네모는 정답 박스와 다르다.


근거: 원본 · 라벨 감사 기록, data/xray_v2/manifest.csv, 전처리 정리본 19의 0~2절.

제1장 데이터 이해 및 진단

탐색적 데이터 분석과 전처리 선택 근거

초기 점검과 시제품 이후 상세 EDA로 전처리를 보완했다. 중복, 라벨 유무, 박스 크기, 색 네모, 촬영 시각을 조사했다.

EDA: 라벨 유무와 이물 박스 크기를 먼저 확인



2026-09-28 분석의 동일 실행기로 2026-10-04 재확인. 박스 크기는 실제 이물 지름과 다름.

EDA 그림. 고유 사진의 라벨 유무와 공식 TXT 박스의 긴 변 분포. 박스 크기는 실제 이물 지름과 다르다.

- ① BMP 2,809개에서 중복 사본 277개를 제외했다. 파일 이름과 내용 해시를 대조해 고유 사진 2,532장을 구분했다.
- ② 라벨은 500장 · 박스 1,147개이며 박스 긴 변 중앙값은 11픽셀이다. 작은 이물 주변을 보존하도록 색 테두리 픽셀만 제거했다.
- ③ 색 네모의 팔레트 번호를 확인했다. 메우기 방법을 비교한 뒤 나비에-스토크스 인페인팅을 적용했다.
- ④ 연속 사진이 반복되어 같은 촬영 묶음을 유지하며 분할했다. 검사기 · 시험편 구성을 고려했다. 실제 정상 제품 평가 표본은 없다.

근거: 원본 EDA 재실행(2026-10-04), 표시 제거 비교(2026-09-29). 기존 원본 · 라벨 · 촬영 구조 통계와 일치했다.

제1장 데이터 이해 및 진단

색 네모만 골라 지우고 주변 영상으로 메우기

원본 BMP의 팔레트 번호 244~255에 해당하는 픽셀만 선택했다. 선택한 자리에는 주변의 밝기와 경계가 이어지도록 나비에-스토크스 인페인팅을 적용했다. 네모 안쪽 전체를 지우거나 마스크를 주변으로 확대하지 않았다.

사진을 고치는 일과 정답 위치를 기록하는 일은 별개입니다



같은 사진의 같은 부분입니다. 지운 선 아래의 원래 밝기는 알 수 없어 주변으로 추정해 메웁니다.

그림 1. 같은 이물 주변의 실제 처리 전·후 사진. 파란 정답 박스는 설명용으로만 덧그렸다.

이 방법의 목적은 장비 표시가 학습 단서가 되는 것을 막으면서 작은 이물 주변의 회색 정보를 남기는 것이다. 색 선 아래의 원래 밝기는 알 수 없으므로, 그 부분은 추정해 메운 결과다. 완전한 원본 복원으로 해석하지 않는다. 사진 크기와 이물 위치를 바꾸지 않았으므로 공식 TXT 좌표를 그대로 짚지었다. 원본 BMP와 공식 TXT는 보존하고 처리 사진은 별도로 저장했다.


제1장 데이터 이해 및 진단

사진 한 장과 TXT 라벨의 관계


TXT 한 줄은 이물 하나의 위치다. 순서는 종류 번호, 중심의 가로 위치, 중심의 세로 위치, 박스 너비, 박스 높이다. 뒤의 네 값은 사진 너비와 높이에 대한 비율이다.

사진 속 이물 3개 = TXT 파일의 3줄

002_20200622_203053(2) | 실제 사진과 공식 TXT를 그대로 찍지은 예시
색 표시를 지은 실제 사진
가로 352 × 세로 332픽셀



이물 부분 확대
번호 = TXT의 줄 순서



② 둘째 줄을 사진 위에 표시하면

0 → 이물(defect)의 종류 번호

중심 가로: $0.619318... \times 352 = 218$ 픽셀

중심 세로: $0.418674... \times 332 = 139$ 픽셀

박스 너비: $0.022727... \times 352 = 8$ 픽셀

박스 높이: $0.024096... \times 332 = 8$ 픽셀

왼쪽 위가 출발점입니다.

가로는 오른쪽으로, 세로는 아래쪽으로 잡니다.

실제 TXT 내용 — 숫자의 순서는 아래와 같습니다

종류 번호 중심 가로 위치 중심 세로 위치 박스 너비 박스 높이

① 0 0.6107954545454546 0.34789156626506024 0.0227272727272728 0.03313253012048193

② 0 0.6193181818181818 0.4186746987951807 0.0227272727272728 0.024096385542168676

③ 0 0.6292613636363636 0.49849397590361444 0.0198863636363636 0.0391566265060241

번호-색 박스는 설명용이며 실제 TXT와 학습 사진에는 없습니다. TXT의 위치-크기는 사진 전체에 대한 비율(0~1)입니다.

그림 2. 실제 사진과 공식 TXT 세 줄. 설명선과 번호는 학습 입력에 포함하지 않는다.

종류 번호 0은 defect를 뜻한다. 이물 0개나 정상이라는 뜻이 아니다. 사진을 자르거나 돌릴 때에는 위치가 달라지므로 박스 좌표도 함께 변환했다.

제1장 데이터 이해 및 진단

촬영 묶음 분할과 학습 자료 구성

같은 검사기에서 촬영 간격이 60초 이내로 이어지는 사진을 한 묶음으로 유지했다. 비슷한 연속 사진이 학습과 평가에 함께 들어가는 것을 줄이기 위한 분할이다. 목표 비율은 60:20:20이며 호기와 시험편 구성도 고려했다. 라벨 누락 의심 묶음은 학습에 고정했다.

분할	사진	정답 이물	촬영 묶음
기본 학습	296	679	67
검증	107	243	24
테스트	97	225	23

296 · 107 · 97이라는 장수를 먼저 정한 것은 아니다. 묶음을 통째로 배정한 결과다. 증강 사진과 의사 라벨은 학습에만 추가한다. 검증과 테스트에는 공식 정답 라벨을 유지한다.


전체 혼합 학습 자료는 2,453장이다. 기본 296장에 자르기 · 회전 885장, 이물 전부 · 일부 제거 175장, 막대 밖 합성 295장, 의사 라벨 802장을 더했다. 같은 사진을 중복 합산하지 않았다.

분할 MD5: 8e58184ae24dfd1b48da2e9dfd88fedc. 같은 묶음 내부 사진은 독립 표본으로 가정하지 않는다.

제1장 데이터 이해 및 진단

사진 전체 변형과 이물 합성 및 제거

직접 생성한 전처리 결과 — 학습 효과는 별도 비교합니다



파란 박스는 저장된 TXT를 그린 설명선입니다. ④는 합성 음성 사진이며 실제 정상 제품을 찍은 사진이 아닙니다.

그림 3. 실제 생성한 학습 사진. 자르기·회전은 제품과 이물을 함께 바꾼다. 파란 선은 변환 라벨을 보여주는 설명선이다.

자르기는 모든 이물 박스가 남는 범위에서 가로·세로 약 80~95%를 남기고 확대했다. 회전은 사진 전체에 -7.5 도와 $+7.5$ 도를 적용했다. 각각 295장과 590장을 만들었다.

이물 전부 제거 82장, 일부 제거 93장은 잔류 검사 통과분이다. 막대 밖 합성 295장은 이물의 어두운 성분을 다른 위치에 추가했다. 합성 정상은 실제 정상 제품을 대체하지 않는다. 자료 생성과 성능 개선 입증은 구분한다.

제1장 데이터 이해 및 진단

AI 의사 라벨의 자동 선별

미라벨 2,032장 중 노란 선 사진 105장과 검증·테스트 촬영 묶음에 속한 27장을 제외했다. 남은 라벨링 후보 데이터셋 1,900장에 대해 YOLOv8n과 RF-DETR-S의 원래 방향 및 좌우 반전 예측을 비교했다.

각 결과에서 이물 신뢰도 점수 0.6 이상인 박스를 남겼다. 네 결과의 박스 개수와 위치가 일치해야 한다. 위치는 중심 거리 4픽셀 이내이면서 IoU 0.4 이상을 요구했다. 중복·크기·사진 경계·설명되지 않은 어두운 점도 검사했다.

분류	사진 수	처리
자동 채택	802	학습용 의사 라벨 1,082개
의심	698	불일치 또는 미해결 후보. 학습 제외
보류	400	기준 예측의 점수 조건 미충족. 학습 제외

보류는 정상 판정이 아니다. 그중 399장에는 다른 모델이나 반전 결과에서 점수 0.6 이상인 예측이 있었다. 자동 채택 기준은 기본 학습 데이터셋 내부에서 조정했다. 공식 검증·테스트 라벨로 바꾸어 쓰지 않았다.

자동 채택 사진은 1·2호기에만 있다. 3호기에는 통과 사진이 없으므로, 모든 호기에 같은 품질로 라벨을 추가했다고 설명하지 않는다.

근거: scripts/xray_pseudo_label.py, 의사 라벨 판정 CSV 및 재검사 기록. 자동 채택은 라벨 정확도의 보증이 아니다.

제2장 AI 예측모델 개발 및 성능평가

구조가 다른 네 탐지 모델

사전학습한 공개 가중치를 이물 탐지 자료에 맞춰 파인튜닝한다. 구조가 다른 모델을 비교하여 특정 방식의 장점이 현재 데이터에서도 나타나는지 확인한다. 프로젝트 비교 기준 모델은 YOLOv8n이다. 제공 예제 노트북의 YOLOv3-SPP와 구분한다.

모델	구조와 비교 목적
YOLOv8n	CNN 한 단계 탐지. 가벼운 비교 기준 모델.
Faster R-CNN ResNet50-FPN v2	CNN 두 단계 탐지. 후보 영역을 찾고 영역별 특징으로 다시 판단. 여러 해상도 특징을 결합.
RF-DETR-S	DINOv2 기반 Vision Transformer 특징과 탐지 decoder. 사진 영역 사이의 관계를 이용.
D-FINE-S	CNN 특징과 Transformer 탐지 decoder. 박스 경계 분포를 단계적으로 보정.

기본 학습 데이터셋의 정답 박스 긴 변 중앙값은 11픽셀이다. 기존 검증 오류에는 이물 근처의 예측 박스가 정답과 충분히 겹치지 않는 사례가 있었다. D-FINE-S는 경계 보정 기능이 이 오류를 줄이는지 시험하기 위해 추가했다. 적합성과 성능 향상은 실험 결과로 판단한다.

구조 근거: Ultralytics YOLOv8, Ren et al. 2015, torchvision Faster R-CNN v2, RF-DETR 공식 구현, D-FINE 논문 · 공식 구현. 출처 목록 참조.

제2장 AI 예측모델 개발 및 성능평가

공통 학습과 저장 모델 선택 규칙

네 모델에 같은 전체 혼합 학습 자료 2,453장과 검증 사진 107장을 사용한다. 입력 해상도 기준은 512, 난수 시드는 0, 학습 예산은 20epoch다. 모델마다 필요한 optimizer 설정은 실행 기록에 남긴다. 같은 epoch 수가 모델별 최적 학습량을 보장하지는 않는다.

매 epoch의 저장 모델로 같은 검증 사진을 추론하고 공통 채점기로 평가한다. IoU 0.5 검증 F1이 가장 높은 저장본을 선택한다. 동점이면 재현율, IoU 0.75 AP, 더 이른 epoch 순서로 선택한다.

탐지 임계값은 검증 데이터셋에서 선택한다. 선택한 모델과 임계값을 고정한 뒤 테스트에 적용한다. 검증 최고 점수는 선택에 사용한 자료의 점수이므로 최종 일반화 성능과 구분한다. 기존 테스트 결과를 이미 열람한 이력도 공개한다.

이전 실험에서 Faster R-CNN의 epoch별 검증 기록이 부족한 점을 보완했다. 네 모델을 각 20epoch 학습하고 같은 검증 선택 규칙을 적용했다. 선택 epoch는 YOLOv8n 20, Faster R-CNN 17, RF-DETR-S 8, D-FINE-S 11이다.

실행: YOLOv8n · RF-DETR-S는 맥북 MPS, Faster R-CNN · D-FINE-S는 Colab T4에서 학습했다. 네 모델 모두 같은 맥북 MPS에서 테스트 추론을 완료했다.

제2장 AI 예측모델 개발 및 성능평가

공통 실험의 모델별 학습 설정

모델	장치와 batch	초기 학습률
YOLOv8n	MPS, 8	0.001
Faster R-CNN	CUDA T4, 4	0.0001
RF-DETR-S	MPS, 4	기본 0.0001 / encoder 0.000015
D-FINE-S	CUDA T4, 4	기본 0.0001 / backbone 0.00005

Optimizer는 네 모델 모두 AdamW다. Weight decay는 YOLOv8n이 0.0005, 나머지 모델이 0.0001이다. YOLOv8n의 최종 학습률 비율 설정은 0.01이다. Faster R-CNN과 D-FINE-S에는 cosine 학습률 감소를 적용했다. RF-DETR-S의 상세 학습률 스케줄은 저장한 학습 설정을 따른다.

한 epoch는 학습 데이터셋을 한 번 순회하는 단위다. Batch는 한 번에 처리하는 사진 수다. 모델별 batch와 내부 optimizer 동작이 달라 업데이트 수까지 같다고 주장하지 않는다. 메모리와 구현 제약을 기록하고 같은 자료
· 20epoch 예산에서 비교한다.

이미 생성한 증강 사진을 동일하게 사용한다. 추가 무작위 기하 증강은 켜다. 네 모델의 학습 손실 정의는 서로 다르므로 손실값의 크기를 모델 간 성능 순위로 사용하지 않는다. 저장본 선택은 공통 검증 F1을 사용한다.

설정 출처: `scripts/xray_train_resumable.py`, `scripts/xray_dfine.py`, `scripts/xray_common_queue.py`. 네 모델 모두 20epoch를 완료했으며 실행 시간과 재개 기록을 보관했다.

제2장 AI 예측모델 개발 및 성능평가

지표 정의와 공통 저장본 비교 결과

점수는 모델이 해당 후보를 이물로 판단하는 강도다. 정답과 비교하여 측정한 정확도나 실제 제조 불량 확률이 아니다. IoU는 예측 박스와 정답 박스의 겹친 면적을 두 박스 전체 면적으로 나눈 값이다.

점수가 탐지 임계값 이상이고 IoU가 0.5 이상이면 정답 대응 후보가 된다. 정답 하나는 예측 하나에만 대응한다. TP는 맞힌 이물, FP는 대응되지 않은 예측, FN은 대응 예측이 없는 정답이다.

모델	검증 F1	테스트 F1	테스트 TP/FP/FN
YOLOv8n	0.9856	0.9889	222/2/3
Faster R-CNN	0.9918	0.9867	222/3/3
RF-DETR-S	0.9918	0.9800	220/4/5
D-FINE-S	0.9856	0.9756	220/6/5

표 1. 검증에서 선택한 네 모델 저장본의 IoU 0.5 결과. 학습 2,453장, 검증 107장 · 이물 243개, 테스트 97장 · 이물 225개. 검증에서 선택한 임계값을 테스트에 그대로 적용했다. 기존 테스트 열람 이력이 있다.

정밀도는 $TP/(TP+FP)$, 재현율은 $TP/(TP+FN)$ 이다. F1은 두 비율의 조화 평균이다. YOLOv8n의 테스트 값은 $2 \times 222 / (2 \times 222 + 2 + 3) = 0.9889$ 다. 이물 단위 점수이며 사진 정확도와 다르다.

YOLOv8n과 Faster R-CNN은 TP 222개 · FN 3개가 같다. FP 한 개 차이로 테스트 F1이 약 0.22%p 다르다. 이 순위만으로 구조의 우열이나 공장 안전성을 확정하지 않는다. 최종 모델과 운영 임계값은 미확정이다.

제3장 영향요인 및 오류분석

미탐의 원인을 사진에서 확인

평균 F1만으로는 이물을 놓친 이유를 설명하기 어렵다. 저장한 예측을 공식 TXT와 대조하여 위치 · 크기 불일치, 탐지 임계값 미달, 대응 정답이 없는 예측을 구분했다.




그림 4. 새 테스트의 실제 이물 확대. 파랑은 공식 TXT, 주황은 채택 예측이다. 검은 점이 박스 안에 보여도 IoU 0.5에 미달하면 위치 기준 FP와 FN으로 기록된다.

기본 학습 자료의 박스 긴 변 중앙값은 11픽셀이고, 679개 중 643개의 긴 변이 15픽셀 이하다. 작은 박스에서는 적은 위치 차이도 IoU를 크게 낮출 수 있다. 이 값은 TXT 박스 크기이며 실제 이물 지름 측정값이 아니다.

네 모델의 테스트 FN 총 16건 중 14건은 근처 채택 박스의 IoU 미달이었다. 서로 다른 이물은 9개다. 확대 사진에서 예측 안에 대상 검은 점이 보였고 TXT 중심도 포함됐다. 픽셀 윤곽 정답은 없으므로 기존 채점값은 유지했다.

크기 · 대비 · 제품 경계까지의 거리 · 박스 종횡비 · 주변 밝기 · 밝기 변동으로 조건을 나눈다. 구간 경계는 학습 자료에서 정한다. 조건별 이물 수와 사진 · 촬영 묶음 수를 함께 보고한다.

제4장 현장 활용방안

출하 위험과 재검사량을 함께 확인

위치 기준 FN은 이물 제품을 실제로 출하했다는 뜻이 아니다. 이물 사진에 채택 박스가 하나도 없으면 사진 단위 무경보로 센다. 이번 테스트에서는 YOLOv8n · RF-DETR-S 각 1장, Faster R-CNN · D-FINE-S 각 0장이었다.

판정	조건과 조치
REJECT	이물 의심이 큰 제품을 분리한다. 실제 자동 배출 임계값은 현장 자료로 검증한다.
RE-INSPECTION	점수가 애매하거나 입력 · 추론에 문제가 있으면 재검사한다. 무검출도 정상으로 자동 확정하지 않는다.
PASS	대표 정상 · 이상 제품과 실제 장치에서 안전성을 검증한 뒤 도입한다. 현재는 자동 PASS를 비활성화한다.

검증과 테스트에는 실제 정상 제품 사진이 없다. 정상 오경보율, 전체 생산품 중 재검사 비율, PASS 안전성을 현재 자료로 추정할 수 없다. 합성으로 이물을 지운 사진은 이 검증을 대신하지 않는다.

재검사는 공장 품질 담당자가 의심 제품을 별도로 다시 확인하는 운영 제안이다. 모델 평가용 사진의 정답 라벨을 다시 만드는 작업과 다르다. 재검사 가능량은 작업자 · 장비가 주어진 시간에 확인할 수 있는 제품 수다. 실제 공장 시험은 아직 하지 않았다.

제4장 현장 활용방안

식품 생산라인의 AI 보조검사 적용안

아래는 현장 적용을 위한 제안이다. 현재 공장에 설치하거나 효과를 측정한 결과는 아니다. 먼저 기존 X-ray 검사와 AI를 병행하여 결과를 기록한다. 이 단계에서는 AI가 기존 장비의 분리 판단을 취소하거나 정상 출하를 승인하지 않는다.

제품이 촬영 지점을 통과하면 제품 식별자, 촬영 시각, 호기와 사진을 묶는다. 현장 PC가 전처리와 추론을 수행하고 의심 위치 · 점수 · 처리 시간을 저장한다. 사진과 제품의 대응이 불명확하면 판정을 보류한다.

재검사 화면에는 사진 전체, 의심 부분 확대, 예측 박스, 장비 판정과 AI 판정의 불일치를 함께 표시한다. 작업자는 해당 제품을 별도 검사하고 실제 이물 여부와 최종 조치를 기록한다. 반복되는 오류는 호기 · 시간대 · 제품별로 모아 점검에 사용한다.

검증 후 분리 장치에 연결할 때에는 제품 식별자와 이동 위치를 설비 제어기에 전달한다. 지연된 판단이 다음 제품을 잘못 분리하지 않도록 촬영부터 배출까지의 시간을 확인한다. 제품 분리 여부를 센서로 확인하고 기록한다.

추론 시간 초과, 사진 누락, 통신 오류, 분리 확인 실패는 정상 판정으로 바꾸지 않는다. 사전에 정한 재검사 · 보류 절차를 적용하고 작업자에게 알린다. 기존 장비의 보호 기능과 최종 조치 권한은 유지한다.

설계 참고: METTLER TOLEDO X-ray Inspection Guidance 5.3 · 6.3 · 17~21절. 분리 확인 · 기록 관리의 산업 사례를 참고했으며, AI 보조검사 흐름과 단계별 적용안은 본 프로젝트의 제안이다.

제4장 현장 활용방안

도입 단계와 효과를 확인하는 방법

단계	실행 범위	확인할 항목
병행 기록	기존 검사 유지, AI 결과만 별도 저장	새 촬영 묶음의 정상 · 이상 제품과 판정 일치
재검사 지원	작업자에게 위치 · 확대 영상과 우선순위 제공	재검사 소요시간, 놓친 이물, 정상 오경보
제한적 자동 연계	검증 조건 안에서 분리 장치 연결	처리 지연, 제품 추적, 분리 확인, 장애 대응

도입 가능성은 네 지표로 확인한다. 이물 제품 중 경보 없이 통과한 비율, 정상 제품 중 경보한 비율, 전체 제품 중 재검사로 보낸 비율, 촬영부터 조치까지의 처리 시간이다. 이물 박스 F1과 함께 보고한다.

검사 속도와 허용 재검사량은 현재 제공되지 않았다. 따라서 제품당 처리 시간의 P95가 설비의 허용 지연 안에 드는지, 단위 시간의 재검사 제품 수가 작업자 처리량 이하인지 현장에서 확인해야 한다. 허용값과 성과 수치를 임의로 만들지 않는다.

기대 효과는 의심 위치를 빠르게 확인하고, 반복 오류의 원인을 추적하며, 새 자료로 모델을 개선하는 것이다. 재검사량 감소나 미탐 감소가 이미 실현됐다는 주장은 하지 않는다. 대표 정상 · 이상 제품으로 확인한 뒤 PASS 적용 여부를 결정한다.

제5장 창의성 및 차별성

추가 자료의 기여와 실패 조건을 검증

전처리의 목적은 이물의 영상 특징을 남기고 장비 표시 의존을 줄이는 것이다. 연속 촬영 자료를 묶어서 평가하고, 의사 라벨은 공식 정답과 구분하여 추적한다. 이 과정을 통해 무엇을 배웠고 무엇을 평가했는지 설명할 수 있게 한다.

자르기 · 회전은 제품과 이물의 관계를 함께 보존한다. 이물 제거와 막대 박합성은 시험편 위치에만 의존하는 학습을 줄일 수 있다는 가설을 시험한다. 의사 라벨은 학습 사진 수를 늘리지만 오류를 함께 늘릴 수도 있다.

앞선 8가지 조건 비교는 같은 업데이트 예산의 단기 실험이었다. 각 조건을 모두 이어 붙이면 기본 사진이 반복된다. 전체 혼합에서는 중복을 정리해 서로 다른 학습 사진 2,453장을 사용했다.

이번 네 모델의 전체 혼합 비교만으로 각 증강의 개별 기여를 확정할 수는 없다. 특정 처리 때문에 성능이 향상됐다는 문장은 동일 모델 · 동일 예산의 대응 실험이 있을 때만 사용한다. 도움이 되지 않은 가설과 적용 한계도 결과에 남긴다.

새 모델의 이름보다 오류와 기능의 연결을 중시한다. D-FINE-S의 경계 보정은 박스 불일치 감소 가설과 연결한다. 박스 점수가 좋아져도 위험 제품의 통과가 줄었는지는 별도로 확인한다.

제6장 코드 구성 및 재현성

데이터와 결과의 연결을 보존

원본은 읽기 전용으로 보존했다. 처리 사진, 공식 라벨 사본, 의사 라벨, 분할 목록과 변환 이력을 분리했다. 각 모델은 같은 데이터 목록을 사용하며 코드 · 환경 · 가중치와 결과 파일의 확인값을 기록한다.

단계	주요 실행 파일
색 네모 제거와 분할	scripts/xray_prepare_v2.py
증강과 전체 혼합	scripts/xray_prepare_roadmap.py scripts/xray_prepare_combined.py
의사 라벨 선별	scripts/xray_pseudo_label.py
재개 가능한 학습	scripts/xray_train_resumable.py scripts/xray_dfine.py
공통 검증과 채점	scripts/xray_epoch_validation.py scripts/xray_eval.py

완료 epoch마다 모델 · optimizer · 학습률 상태와 난수 상태를 저장한다. 복구 전에 설정 · 파일 확인값을 검사한다. 중단 시 마지막으로 검증된 epoch 부터 이어서 학습한다. Colab 결과는 Drive에 저장한다. 세션이 자동 재연결 된다는 뜻은 아니다.

CPU와 실제 MPS · CUDA의 작은 실행에서 저장 · 종료 · 재개를 확인했다. 제출 ZIP의 깨끗한 환경 재현과 최종 예측 파일 연결은 아직 점검 전이다. 실행하지 않은 범위를 재현 완료라고 적지 않는다.

제출 ZIP에는 소스코드, 환경 명세, 학습용 데이터, README, 테스트 예측 결과를 포함한다. 보고서 PDF와 발표자료 PDF · PPT는 별도 제출한다.

참고자료

자료와 방법의 출처

- [1] 제6회 K-인공지능 제조데이터 분석 경진대회 안내, 3~4쪽. 결과보고서 양식, X-ray 추가 안내.
- [2] Ultralytics. YOLOv8 공식 모델 문서. <https://docs.ultralytics.com/models/yolov8/>
- [3] Ren et al. Faster R-CNN. NeurIPS 2015. <https://arxiv.org/abs/1506.01497>
- [4] He et al. Deep Residual Learning for Image Recognition. CVPR 2016. <https://arxiv.org/abs/1512.03385>
- [5] Lin et al. Feature Pyramid Networks for Object Detection. CVPR 2017. <https://arxiv.org/abs/1612.03144>
- [6] Torchvision. fasterrcnn_resnet50_fpn_v2 공식 API. https://docs.pytorch.org/vision/0.23/models/generated/torchvision.models.detection.fasterrcnn_resnet50_fpn_v2.html
- [7] Oquab et al. DINOv2. <https://arxiv.org/abs/2304.07193>
- [8] Roboflow. RF-DETR 공식 구현. <https://github.com/roboflow/rf-detr>
- [9] Peng et al. D-FINE. 공식 구현과 논문 링크. <https://github.com/Peterande/D-FINE>
- [10] METTLER TOLEDO. X-ray Inspection Guidance, 5.3 · 6.3 · 17~21절. <https://www.mt.com/nz/en/home/library/know-how/product-inspection/PI-Guides/xray-inspection-guide/x-ray-inspection-wiki.html>
- [11] 프로젝트 근거: data/xray_v2/manifest.csv, data/xray_combined_20261003/provenance.json, reports/overnight_20261003/diagnostics/model_selection_comparison.json, docs/evidence/condition_audit_20261003/summary.json, reports/common_epoch_20261004/evaluation_policy.json.

실제 전처리 · 예측 그림은 프로젝트 파일에서 생성했다. 공통 20epoch의 선택 저장본 테스트 결과와 EDA를 반영했다. 최종 모델 선정, 운영 임계값과 현장 검증은 남아 있다. 공통 결과 근거:

reports/common_epoch_20261004/evaluation/comparison.csv 및 diagnostics/.

경진대회 만족도 조사

완료 화면 첨부란

설문 완료 화면은 팀에서 응답한 뒤 첨부한다. 현재 검토본에는 완료 화면이 없다.

설문 주소: <https://naver.me/FetWt7SN>

최종 제출 전 확인 항목: 팀명과 프로젝트명 확정, 성명과 서명, 설문 완료 화면, 최종 모델과 운영 기준, 제출 ZIP 재현, 지정 글꼴과 포털 추가 공지.